

Trabalho de Pesquisa

ARQUITETURA DE DADOS

TEMA DO TRABALHO: APACHE SPARK COM DELTA LAKE E APACHE ICEBERG

- Grupos de no máximo 3 alunos.
- Criar um único repositório/projeto público no GitHub, adicionar os participante como membros e encaminhar por e-mail para jorge.silva@satc.edu.br com o link do repo e o nome de todos os participantes **até as 22h do dia 15/04**.
- Criar um único ambiente PySpark e Jupyter Labs (podem usar o Jupyter Extensão do Visual Studio Code), implementando Delta Lake (1 arquivos .ipybnp) e Apache Iceberg (.ipybnp).
- Descrever o passo a passo para reproduzir o seu ambiente no arquivo README (instruções bem detalhadas, bibliotecas, versões, etc). Faça uso dos recursos de markdown – copy code, formatação, links, etc. Utilize IA para auxilio.

Trabalho de Pesquisa

ARQUITETURA DE DADOS

TEMA DO TRABALHO: APACHE SPARK COM DELTA LAKE E APACHE ICEBERG

- Podem utilizar como fonte de pesquisa os vídeos do canal do youtube DataWay BR.
- Projetos do github: github.com/jlsilva01/spark-delta e github.com/jlsilva01/spark-iceberg
- Utilizem o padrão de projetos Python descrito em aula (Python para Engenharia de Dados - material de apoio.pdf)
- Escolham apenas um gerenciador de projetos/pacote python e o utilizem em todo o seu projeto. POETRY ou UV.

Trabalho de Pesquisa

ARQUITETURA DE DADOS

TEMA DO TRABALHO: APACHE SPARK COM DELTA LAKE E APACHE ICEBERG

- Descreva o cenário da(s) tabela(s) em um arquivo tipo notebook – modelo ER, imagens e códigos DDL - e da fonte de dados utilizada (qualquer fonte de dados) e evidencie e explique, com exemplos, os comandos de INSERT, UPDATE e DELETE nas tabelas Delta e Iceberg dentro do Apache Spark **através do MKDOCS** (1 página web para contextualização do trabalho, 1 página web para explicar Apache Spark (pyspark), 1 página web para explicar Iceberg, 1 página web para explicar Delta). Utilizem IA para auxílio.
- Publicar o MKDOCS para uma URL publica (**mkdocs gh-deploy**)



Trabalho de Pesquisa

ARQUITETURA DE DADOS

TEMA DO TRABALHO: APACHE SPARK COM DELTA LAKE E APACHE ICEBERG

- A atividade valerá **2 pontos** em cima da Avaliação A2.
- O projeto deverá ser apresentado para o professor funcionando (10 min no máximo). Se não funcionar, fica sem nota. Se funcionar parcialmente, a nota será parcial.
- Caso o projeto funcione, será avaliado também:
 - Organização do Github,
 - Estrutura do README,
 - Documentação do MKDOCS (lembre-se README é diferente de MKDOCS, eles tem propósitos diferentes).

Prazo para entrega: 29/04.

